COMPET MOURA · CIÊNCIA DE DADOS

ATIVIDADE 4.

Correção dos dados e Hitachi no MTSA

BASE DO TRABALHO

CristoferSilva / mtsa-tutorial-compet

github.com/CristoferSilva/mtsa-tutorial-compet · commit a595946

Luan César de Souza Nascimento
Engenharia de Controle e Automação · UFPE · 21/10/2026

O DESAFIO

Duas partes, um tutorial.

PARTE I

Achar o problema

Em `get_tabular_sample_data()`, a função que monta os dados tabulares com anomalias sintéticas.

PARTE II

Hitachi no framework

Treinar e avaliar o autoencoder Hitachi com o mesmo fluxo do exemplo do GANF, no conjunto tabular.

Todo o trabalho foi feito sobre o repositório **`github.com/CristoferSilva/mtsa-tutorial-compet`** (commit `a595946`). Os dados são o CSV sintético do tutorial: 5.000 linhas, 6 variáveis. Não são dados da Moura.

✳ PARTE I · O ERRO

Uma fatia vazia não avisa.

```
# original: o 1º intervalo usa step como FIM
(start_point or step, step)
# os outros três usam step como DURAÇÃO
(2*step, 3*step), (4*step, 5*step), ...

# correção
first_start = (step if start_point is None
               else start_point)
(first_start, first_start + step)
```

O **or** também descartava um início zero. Agora intervalos vazios ou fora dos dados geram erro.

STEP=13, INÍCIO=200

[200:13]

→ 0 linhas alteradas

STEP=200, INÍCIO=150

50 de 200

linhas na 1ª faixa

ANOMALIAS NO TESTE ORIGINAL

676 → 826

após a correção

Evidência: seção 3 do notebook

Ordem temporal importa.

ORIGINAL

Teste por classe

`vstack([normais, anômalos])`: trechos colados que nunca foram vizinhos.

- 11 emendas no teste
- 121 de 1.641 janelas de 12 linhas cruzam emendas
- treino com linhas posteriores ao teste

ENTREGA

Blocos cronológicos

Linhas 0-2999 normais para treino e validação; 3000-4999 para teste, com anomalias só nele.

- 0 emendas
- treino inteiro antes do teste
- padronização ajustada só no treino

Não é vazamento de rótulo: nenhuma linha está nos dois conjuntos. É perda da ordem temporal, que afeta modelos com janelas como o GANF. É uma mudança de protocolo, separada da correção do intervalo.

Evidência: seção 3 do notebook

✳ PARTE II · INTEGRAÇÃO

O mesmo fluxo do GANF.

HIPÓTESES

Hitachi(6)

6→64→64→8→64→64→6, já existia no tutorial

GANF: GANF(...)

ERRO

MSELoss

entrada = alvo, reconstrução

GANF: LagrangeLoss

OTIMIZADOR

Adam

taxa 0,001, lote 64

GANF: Adam

APRENDIZADO

Unsupervised Trainer

30 épocas, só normais

GANF: LagrangeTrainer

PREDIÇÃO

Standard Predictor

+ HitachiScore: MSE por linha, maior = mais anômalo

GANF: StandardPredictor

A peça que faltava era o **HitachiScore**: o GANF já devolve um escore, o Hitachi devolve a reconstrução. O adaptador calcula o erro e tira o canal extra do preditor: `(1, 1, 6, 1)` → `(1,)`.

Janela 1: cada linha de seis variáveis é um exemplo. Com seis entradas, a camada de 8 unidades **não comprime** a entrada. A arquitetura do tutorial foi mantida.

Evidência: seção 5 do notebook · mtsa/predictors/hitachi_score.py

✳ RESULTADOS · 5 SEEDS

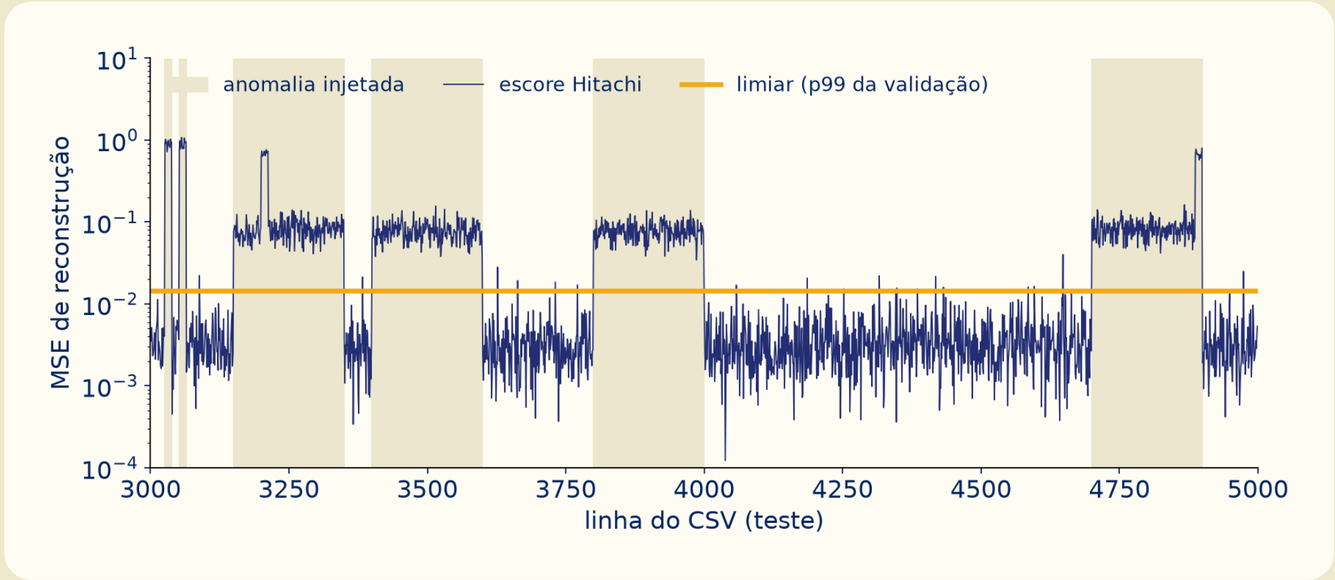
Quase perfeito, e fácil.

F1 HITACHI
0,993
± 0,003 entre seeds

F1 BASELINE
0,991
regra sem treino

RECALL
1,0
nos dois métodos

FALSOS ALARMES
7-18
de 1.174 normais
(baseline: 15)



As anomalias são degraus de 10 a 46 desvios-padrão. A regra simples também acerta tudo, e a diferença de F1 vem de poucos falsos alarmes. Não dá para dizer que o Hitachi é melhor.

Limiar: percentil 99 da validação normal · seeds 11, 22, 33, 42, 55 fixadas antes

PERGUNTA 1

Qual foi a parte mais desafiadora?

Confiar nos dados antes de confiar no modelo.

O erro do intervalo não quebra nada: o código roda e as métricas saem. Ele só aparece quando se conta quantas linhas foram de fato alteradas.

Depois, separar correção de mudança de protocolo, e entender por que até uma regra sem treino tirava nota perto de 1.

PERGUNTA 2

Conclusões.

PARTE I

Intervalo corrigido

O 1º intervalo usava `step` como fim. Com fim = início + duração, o teste passa de 676 para 826 anomalias. O teste também deixou de ser montado por classe.

PARTE II

Hitachi integrado

Treina e pontua no framework, com F1 0,993 e recall 1,0. O baseline teve F1 0,991: o conjunto sintético não diferencia os métodos.

Limites: um arquivo sintético, uma divisão fixa, anomalias grandes e constantes. O GANF não foi reexecutado neste protocolo, então não há comparação entre os dois. Repositório: `github.com/CristoferSilva/mtsa-tutorial-compet`.